

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación




IIC2613 – Inteligencia Artificial

Análisis de regresión – Regresión Lineal

Denis Parra
Dpto. Ciencia de la Computación

Consideremos el siguiente conjunto de puntos, que presentan el precio de un departamento en función de su superficie




¿Cómo podemos estimar el precio de un departamento de 150m²?

¿Y el de uno de 30m²?

Análisis de regresión es una técnica simple y poderosa

- Técnica de estimación de funciones.
- Altamente flexible e interpretable.
- Permite realizar regresión y clasificación.
- Nos centraremos en dos tipos de regresión: lineal y logística.



Regresión lineal permite estimar funciones continuas de manera supervisada

- El espacio de hipótesis de una regresión lineal es el conjunto de las funciones lineales que mapean los vectores x_i del dominio, a escalares y_i .
- Al parametrizar este espacio de hipótesis a través del vector de parámetros (pesos), obtenemos la siguiente expresión:

$$h(x) = \sum_{i=0}^n \theta_i x_i = \theta^T x$$

¿Cómo podemos obtener los valores de los pesos θ ?

Regresión lineal permite estimar funciones continuas de manera supervisada

- Si tenemos suficientes datos, pares $(x^{(i)}, y^{(i)})$ es posible construir una función que nos indique cuán buena es en promedio la estimación.
- Definimos entonces la **función de pérdida** (o costo, o error) de la regresión de la siguiente manera:

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- El valor para los pesos que minimice esta pérdida, entregará la mejor estimación de la función original (¿por qué?, ¿seguro?).

$$Err(x) = E \left[(Y - \hat{f}(x))^2 \right]$$

$$Err(x) = \left(E[\hat{f}(x)] - f(x) \right)^2 + E \left[\left(\hat{f}(x) - E[\hat{f}(x)] \right)^2 \right] + \sigma_e^2$$

$$Err(x) = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$

Alternativa 1: solución analítica del problema de mínimos cuadrados (OLS, *ordinary least squares*)

Asumiendo que tenemos N ejemplos para entrenar, podemos plantear el sistema de ecuaciones matricialmente como

$$Y = X\theta$$

$$\text{donde } Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} \in \mathbb{R}^N, X = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1M} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{N1} & x_{N2} & \dots & x_{NM} \end{pmatrix} \in \mathbb{R}^{N \times M} \text{ y } \theta \in \mathbb{R}^M$$

Alternativa 1: solución analítica del problema de mínimos cuadrados (OLS, *ordinary least squares*)

Para medir la calidad del modelo usamos la suma de errores cuadrados, la cual en notación matricial es

$$L(\theta) = \frac{1}{2} (Y - X\theta)^T (Y - X\theta)$$

Si derivamos e igualamos a cero la expresión anterior se obtiene

$$\nabla_{\theta} L(\theta) = -X^T (Y - X\theta) = 0,$$

despejando la solución es

$$\hat{\theta} = (X^T X)^{-1} X^T Y$$

siempre $X^T X$ no sea singular (no invertible).

Implementación OLS en sk-learn

La solución de mínimos cuadrados está implementada en la librería scikit-learn como

`sklearn.linear_model.LinearRegression`.

Sus principales argumentos son:

- `fit_intercept=True`: Ajustar o no el parámetro θ_0
- `n_jobs`: Número de núcleos de CPU para ajustar

Sus principales métodos son:


- `fit(X, y)`: Ajuste los parámetros según la solución de mínimos cuadrados.
- `predict(X)`: Retorna la predicción para un conjunto de datos
- `score(X, y)`: Retorna el **coeficiente de determinación**

Nota

- `X` es un *ndarray* de dos dimensiones (matriz)
- `y` es un *ndarray* de una dimensión (vector)

Fuente: https://phuijse.github.io/MachineLearningBook/contents/supervised_learning/linear.html

Implementación OLS en sk-learn



El gráfico de residuos es un gráfico de dispersión (*scatter plot*) de y versus $y - f_{\theta}(x)$. Es bastante usado para analizar los errores de un modelo de regresión.

Importante

Un modelo adecuado debería tener sus residuos concentrados en torno a cero y libres de correlación.

También podemos medir la calidad del modelo utilizando el error medio cuadrático, que es la suma de errores cuadrados dividido por la cantidad de datos:

```
from sklearn.metrics import mean_squared_error
print(f"MSE: {mean_squared_error(y, model.predict(x.reshape(-1, 1))):0.4f}")
```

MSE: 24.1281

Mientras más cercano a cero sea el MSE, mejor es el ajuste del modelo.

Alternativa 2: Regresión polinomial

Podemos generalizar el regresor lineal aplicando transformaciones a los datos. Por ejemplo una regresión polinomial de grado M sería

$$f_{\theta}(x_i) = \theta_0 + \sum_{j=1}^M \theta_j x_i^j,$$

y su solución sería


$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y,$$

donde

$$\Phi = \begin{pmatrix} 1 & x_1 & x_1^2 & \dots & x_1^M \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_N & x_N^2 & \dots & x_N^M \end{pmatrix}$$

En sk-learn: Polynomial features y Linear Regression


Grado 2



```
model.fit(x.reshape(-1, 1), y)
print(f"MSE: {mean_squared_error(y, model.predict(x.reshape(-1, 1))):0.4f}")
y_test = model.predict(x_test.reshape(-1, 1))
```

MSE: 0.7179

Grado 15



```
model = make_pipeline(PolynomialFeatures(degree=15),
                      LinearRegression())

model.fit(x.reshape(-1, 1), y)
print(f"MSE: {mean_squared_error(y, model.predict(x.reshape(-1, 1))):0.4f}")
y_test = model.predict(x_test.reshape(-1, 1))
```

MSE: 0.2526


Dificultades de la alternativa 1: costo computacional



- La inversión de grandes matrices puede ser muy costoso computacionalmente $O(n^3)$
- Otra solución es usar descenso de gradiente

Alternativa 2: Usemos un poco de **optimización** convexa clásica para solucionar el problema

- Dado que la pérdida es **convexa**, podemos usar un algoritmo de descenso desde cualquier punto de inicio para encontrar el **óptimo**

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$








Usemos un poco de **optimización convexa** clásica para solucionar el problema

- Dado que la pérdida es **convexa**, podemos usar un algoritmo de descenso desde cualquier punto de inicio para encontrar el **óptimo**.
- En particular, podemos utilizar la dirección opuesta a la entregada por el **gradiente de la** pérdida (máximo decrecimiento de la función).
- Si avanzamos en esta dirección usando pequeños pasos, tenemos un algoritmo iterativo para encontrar el óptimo:

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

- Donde α es conocido como tasa de aprendizaje o *learning rate*.





Algoritmo final es simple e intuitivo

- Podemos finalmente darle una forma a nuestro algoritmo de **descenso** basado en **mínimos cuadrados**:

$$\theta_j := \theta_j + \alpha \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$

- Una propiedad interesante de este algoritmo, es que la actualización de los parámetros es **proporcional al error** (mientras más cerca del óptimo, menos se corrige).
- ¿Qué podría pasar con este algoritmo si la pérdida no es convexa?

¿Cómo interpretar los coeficientes de regresión lineal?

$$\text{Precio} = \theta_0 + \theta_1 \cdot \text{m}^2 + \theta_2 \cdot \text{piezas} + \theta_3 \cdot \text{baños} + \theta_4 \cdot \text{estacionamientos}$$

$$\begin{aligned} \text{Precio} = & 12.000.000 + 45.000 \cdot \text{m}^2 + 3.200.000 \cdot \text{piezas} + 2.800.000 \cdot \text{baños} \\ & + 4.500.000 \cdot \text{estacionamientos} \end{aligned}$$

Fuente: https://phuijse.github.io/MachineLearningBook/contents/supervised_learning/logistic.html

¿Cómo interpretar los coeficientes de regresión lineal?

$$\text{Precio} = 12.000.000 + 45.000 \cdot \text{m}^2 + 3.200.000 \cdot \text{piezas} + 2.800.000 \cdot \text{baños} + 4.500.000 \cdot \text{estacionamientos}$$

- $\theta_0 = 12.000.000$: Es el precio base cuando todas las variables valen cero. En este caso no tiene interpretación práctica útil (un departamento de 0 m², 0 piezas, etc. no existe), pero es necesario para que la recta pueda ajustarse correctamente.
- $\theta_1 = 45.000$: Cada metro cuadrado adicional se asocia con un aumento de \$45.000 en el precio, manteniendo todas las demás variables constantes.
- $\theta_2 = 3.200.000$: Cada pieza adicional se asocia con un aumento de \$3.200.000, manteniendo m², baños y estacionamientos constantes.
- $\theta_3 = 2.800.000$: Cada baño adicional se asocia con un aumento de \$2.800.000, manteniendo el resto constante.
- $\theta_4 = 4.500.000$: Cada estacionamiento adicional se asocia con un aumento de \$4.500.000, manteniendo el resto constante.

La frase "manteniendo el resto constante" es fundamental y siempre debe estar implícita en la interpretación. Cada coeficiente mide el efecto marginal de esa variable, aislado de las demás.

Condiciones para que la interpretación sea válida

- **Linealidad:** la relación entre cada feature y el precio debe ser aproximadamente lineal. Si el precio crece exponencialmente con los m^2 , el coeficiente no captura bien la relación.
- **No multicolinealidad:** las variables no deben estar altamente correlacionadas entre sí. Si m^2 y número de piezas están muy correlacionados (los departamentos más grandes siempre tienen más piezas), los coeficientes individuales se vuelven inestables y difíciles de interpretar en forma aislada.
- **Los coeficientes son asociaciones, no causalidad:** un coeficiente positivo en "baños" no significa que agregar un baño causará que el precio suba \$2.800.000. Puede haber variables omitidas (como la ubicación o el piso) que expliquen parte de esa asociación.
- **Las variables están en sus unidades originales:** la interpretación directa en pesos solo aplica cuando las variables no han sido estandarizadas. Si estandarizas las variables (media 0, desviación 1), la interpretación cambia: el coeficiente pasa a medir el cambio en precio por cada desviación estándar de aumento en la variable.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación




IIC2613 – Inteligencia Artificial

Análisis de regresión – Regresión Logística


Denis Parra
Dpto. Ciencia de la Computación

Veamos ahora como resolver un problema de clasificación con análisis de regresión

- Un problema de clasificación difiere de una regresión en que la salida de este puede tomar ahora sólo un pequeña cantidad de valores discretos.
- En particular, un problema de clasificación de alto interés es la clasificación binaria ($1 =$ clase positiva, $0 =$ clase negativa).
- ¿Cómo funcionaría una regresión lineal para resolver un problema de clasificación?



La función logística permite modelar el cambio en la probabilidad de ocurrencia de un evento




$$g(z) = \frac{1}{1 + e^{-z}}$$

La regresión logística permite resolver los problemas de la regresión lineal al clasificar


- La principal diferencia entre ambas regresiones, es que la logística utiliza un espacio de hipótesis distinto. Más específicamente, parametrizamos el espacio de hipótesis usando la función logística de la siguiente manera:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Linear Regression



Logistic Regression



Utilicemos ahora un enfoque probabilístico para obtener los pesos óptimos

- Definamos inicialmente las probabilidades de cada una de las dos clases:

$$\begin{aligned} P(y = 1 \mid x; \theta) &= h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}} \\ P(y = 0 \mid x; \theta) &= 1 - h_{\theta}(x) \end{aligned}$$

- Esto puede escribirse de manera más conveniente como:

$$p(y \mid x; \theta) = (h_{\theta}(x))^y (1 - h_{\theta}(x))^{1-y}$$



Utilicemos ahora un **enfoque probabilístico** para obtener los pesos óptimos


- Con lo que nuestra regla de actualización queda de la siguiente manera, entropía cruzada binaria o BCE:

$$\ell(\theta) = \sum_{i=1}^m y^{(i)} \log h(x^{(i)}) + (1 - y^{(i)}) \log(1 - h(x^{(i)}))$$

$$\frac{\partial}{\partial \theta_j} \ell(\theta) = (y - h_{\theta}(x)) x_j$$

$$\theta_j := \theta_j + \alpha \sum_{i=1}^m (y^{(i)} - h_{\theta}(x^{(i)})) x_j^{(i)}$$





En sk-learn

```
from sklearn.linear_model import LogisticRegression

model = LogisticRegression(penalty=None)
model.fit(X, y)

print(model.intercept_, model.coef_)
```

```
[-2.44751183] [[-3.3470849  4.81780968]]
```

A continuación se muestra la diferencia entre `predict` y `predict_proba` para un dato ubicado en `[1., 0.]`

```
display(model.predict_proba(np.array([[1., 0.]))),
        model.predict(np.array([[1., 0.])))
```


```
array([[0.99696528, 0.00303472]])
```

```
array([0])
```

```
y_soft = model.predict_proba(X[:, 1])
y_hard = model.predict(X)
```

```
fig, ax = plt.subplots(1, 2, figsize=(9, 4), tight_layout=True)

for ax_, pred in zip(ax, [y_hard, y_soft]):
    for y_, marker in zip(np.unique(y), ['o', 'd']):
        mask = y == y_
        artist = ax_.scatter(X[mask, 0], X[mask, 1], c=pred[mask], marker=marker, s=100,
                             vmin=0, vmax=1, cmap=plt.cm.RdBu_r, edgecolors='k', linewidths=1)
    fig.colorbar(artist, ax=ax_);
```



El tipo de símbolo corresponde a la etiqueta real mientras que el color corresponde a la etiqueta predicha.

¿Cómo interpretar los coeficientes de regresión logística?

- La regresión logística no predice directamente si el auto se recupera o no, sino la probabilidad de recuperación:

$$P(\text{recuperado} = 1) = \sigma(\theta^\top \mathbf{x}) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \dots + \theta_k x_k)}}$$

- Supón que ajustas el modelo con las variables: año del auto, si es marca premium (0/1), color llamativo (0/1), y hora del robo (hora del día 0-23), y obtienes:

$$z = -1.2 + 0.08 \cdot \text{año} - 0.9 \cdot \text{premium} + 0.4 \cdot \text{color_llamativo} - 0.05 \cdot \text{hora}$$

Interpretación: Logaritmo de odds ratio

- Se define los odds como:

$$\text{odds} = \frac{P(\text{recuperado})}{1 - P(\text{recuperado})}$$

- Luego, lo que nos da el modelo es:

$$\log(\text{odds}) = \theta_0 + \theta_1 x_1 + \dots + \theta_k x_k$$

$$z = -1.2 + 0.08 \cdot \text{año} - 0.9 \cdot \text{premium} + 0.4 \cdot \text{color_llamativo} - 0.05 \cdot \text{hora}$$

Cómo interpretar

- Entonces los coeficientes sí son lineales, pero en escala logarítmica del odds. Para interpretar en escala natural se exponencia cada coeficiente, obteniendo el Odds Ratio (OR):

Variable	θ	OR = e^{θ}	Interpretación
año	0.08	1.083	Cada año más reciente multiplica el odds de recuperación por 1.083, es decir lo aumenta un 8.3%, <i>ceteris paribus</i>
premium	-0.90	0.407	Ser marca premium reduce el odds de recuperación a un 40.7% de lo que sería si no fuera premium, es decir lo reduce un 59.3%
color llamativo	+0.40	1.492	Tener color llamativo aumenta el odds de recuperación en un 49.2%
hora	-0.05	0.951	Cada hora más tarde en el día reduce el odds de recuperación en un 4.9%

Condiciones para interpretación válida

- **Linealidad en el log-odds:** la relación entre cada variable continua y el log-odds debe ser aproximadamente lineal. Si la hora del robo tiene un efecto no lineal (robos a las 3am vs mediodía vs 6pm), el coeficiente único no captura bien la relación.
- **No multicolinealidad:** igual que en regresión lineal, si marca y modelo están muy correlacionados, los coeficientes individuales son inestables.
- **Independencia de observaciones:** cada robo debe ser independiente de los otros. Si hay robos del mismo delincuente o zona con patrones similares, esto puede violarse.
- **El OR es una asociación, no causalidad:** que autos premium tengan menor odds de recuperación no significa que ser premium cause que sea más difícil de recuperar.
- **Muestra suficiente:** la regresión logística necesita aproximadamente 10 eventos por variable incluida en el modelo para que los coeficientes sean estables. Si tienes 5 variables y solo 30 autos recuperados en tu dataset, los coeficientes serán poco confiables.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2613 – Inteligencia Artificial

Análisis de regresión – Regresión Logística

Denis Parra
Dpto. Ciencia de la Computación