

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2613 - Inteligencia Artificial

Support Vector Machines (SVM)


Denis Parra
Dpto. Ciencia de la Computación

Recapitulemos nuevamente lo que hemos visto hasta ahora en el curso


- Comenzamos con los conceptos fundamentales de ML.
- Luego exploramos árboles y ensambles, siempre teniendo en consideración el *trade-off* entre complejidad y sobreajuste.
- Hoy veremos una técnica que fue el estado del arte durante largo tiempo, y captura algunos conceptos centrales de lo que es ML moderno.



Visualicemos un problema binario de clasificación en 2D,
¿cómo podríamos separar estas clases usando una línea?




Existen múltiples soluciones, muchas incluso con rendimiento perfecto. Pero ¿existe una “mejor” que el resto?




¿Cómo podríamos incorporar algo relacionado con la capacidad de generalización en la solución?

El (hiper)plano óptimo es aquel que separa las dos categorías con el máximo margen




Mientras mayor sea la distancia entre el hiperplano y los puntos, mayor espacio existe para los datos difíciles

Hagamos un breve repaso del álgebra lineal necesaria para este capítulo




- El vector de coeficientes β es ortogonal al hiperplano $y(x) = \beta_0 + \beta^T x = 0$ ¿por qué?

Hagamos un breve repaso del álgebra lineal necesaria para este capítulo




- El vector de coeficientes β es ortogonal al hiperplano $y(x) = \beta_0 + \beta^T x = 0$ ¿por qué?
 - Supongamos que tenemos dos puntos x_A y x_B , ambos sobre el hiperplano
 - Se cumple que $\beta_0 + \beta^T x_A = \beta_0 + \beta^T x_B = 0$

Hagamos un breve repaso del álgebra lineal necesaria para este capítulo




- El vector de coeficientes β es ortogonal al hiperplano $y(x) = \beta_0 + \beta^T x = 0$ ¿por qué?
 - También se cumple que $\beta_0 + \beta^T x_A - (\beta_0 + \beta^T x_B) = 0 \Rightarrow \beta^T (x_A - x_B) = 0$
 - El vector $(x_A - x_B)$ está justo sobre el hiperplano y al hacer producto punto con $\beta = 0$
 - Por lo tanto, β es ortogonal al hiperplano
 - Los coeficientes β nos indican entonces la orientación del hiperplano

Hagamos un breve repaso del álgebra lineal necesaria para este capítulo



- Un punto cualquiera x ¿a qué distancia está del hiperplano?


Hagamos un breve repaso del álgebra lineal necesaria para este capítulo



- Para cualquier par de puntos x_A y x_B en el hiperplano, se cumple: $\beta^T(x_A - x_B) = 0$
- El vector unitario normal al hiperplano está dado por: $\beta^* = \beta^T / \|\beta\|$
- Para cualquier punto x , la **distancia signada** entre él y el hiperplano está dada por (*¿por qué?*):

$$\beta^{*T}(x - x_0) = \frac{1}{\|\beta\|}(\beta^T x + \beta_0)$$

Hagamos un breve repaso del álgebra lineal necesaria para este capítulo




- Para cualquier punto x , la distancia signada entre él y el hiperplano está dada por:


$$\beta^*(x - x_0) = \beta^*(x - (-\beta_0 / \beta^T)) = \beta^T / \|\beta\| (x + \beta_0 / \beta^T) = 1 / \|\beta\| (\beta^T x + \beta_0)$$

$$\beta^{*T} (x - x_0) = \frac{1}{\|\beta\|} (\beta^T x + \beta_0)$$

Resumiendo




Distancia de un punto al hiperplano (**margen**) es la clave de los **SVM**



$$D = \frac{y}{\|\beta\|} (x^T \beta + \beta_0)$$


Distancia de un punto al hiperplano (**margen**) es la clave de los **SVM**



¿Cómo puedo tomar esto y plantear un problema de optimización para encontrar el hiperplano?

Partamos por lo básico, ¿qué es lo que queremos maximizar o minimizar?

*Nos interesa maximizar el
margen M*




$\max M$

A continuación, ¿qué queremos obtener como resultado?

Nos interesa maximizar el margen M

Queremos encontrar los valores de parámetros β y β_0 que maximizan dicho margen




$$\max_{\beta, \beta_0} M$$

¿Qué condiciones debe cumplir nuestro hiperplano óptimo?

Nos interesa maximizar el margen M

Queremos encontrar los valores de parámetros β y β_0 que maximizan dicho margen

Sujetos a la condición de que la distancia de cualquier punto al hiperplano sea mayor que M




$$D = \frac{y}{\|\beta\|} (x^T \beta + \beta_0)$$

$$\max_{\beta, \beta_0} M$$


$$\text{subject to } \frac{1}{\|\beta\|} y_i (x_i^T \beta + \beta_0) \geq M, \quad i = 1, \dots, N$$

Ahora, acomodaremos los términos para facilitar la resolución



$$\begin{aligned} & \max_{\beta, \beta_0} M \\ \text{subject to } & \frac{1}{\|\beta\|} y_i (x_i^T \beta + \beta_0) \geq M, \quad i = 1, \dots, N \end{aligned}$$

Ahora, acomodaremos los términos para facilitar la resolución



$$\max_{\beta, \beta_0} M$$

$$\text{subject to } y_i(x_i^T \beta + \beta_0) \geq M \|\beta\|, \quad i = 1, \dots, N$$


Ahora, acomodaremos los términos para facilitar la resolución

~~Nos interesa maximizar el margen M~~

Nos interesa minimizar la norma del vector de coeficientes β

Queremos encontrar los valores de parámetros β y β_0 que ~~maximizan dicho margen~~ minimizan la norma de β

Sujetos a la condición de que el producto entre la etiqueta real y_i y el valor de la función $y(x_i)$ sea mayor o igual que 1



$$\min_{\beta, \beta_0} \|\beta\|$$

$$\text{subject to } y_i(x_i^T \beta + \beta_0) \geq 1, \quad i = 1, \dots, N$$


Ahora, acomodaremos los términos para facilitar la resolución

~~Nos interesa maximizar el margen M~~

Nos interesa minimizar la norma del vector de coeficientes β

Queremos encontrar los valores de parámetros β y β_0 que ~~maximizan dicho margen~~ minimizan la norma de β

Sujetos a la condición de que el producto entre la etiqueta real y_i y el valor de la función $y(x_i)$ sea mayor o igual que 1




$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2$$

subject to $y_i(x_i^T \beta + \beta_0) \geq 1, i = 1, \dots, N$

Ajustamos el término a optimizar por conveniencia posterior ya que es equivalente al anterior

Veamos cómo podemos resolver este problema (hard-margin SVM)



$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2$$

subject to $y_i(x_i^T \beta + \beta_0) \geq 1, i = 1, \dots, N$



Lagrangiano

$$\min_{\beta, \beta_0} \max_{\alpha_i \geq 0} L_P = \frac{1}{2} \|\beta\|^2 - \sum_{i=1}^N \alpha_i [y_i(x_i^T \beta + \beta_0) - 1]$$

Veamos cómo podemos resolver este problema (**hard-margin SVM**)

$$L_P = \frac{1}{2} \|\beta\|^2 - \sum_{i=1}^N \alpha_i [y_i (x_i^T \beta + \beta_0) - 1]$$

Derivando e igualando a cero con respecto a β y β_0 , respectivamente, obtenemos:

$$\beta = \sum_{i=1}^N \alpha_i y_i x_i \qquad 0 = \sum_{i=1}^N \alpha_i y_i$$

Sustituyendo todo esto en el **lagrangiano**, obtenemos el problema **dual**:

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^N \alpha_i \alpha_k y_i y_k x_i^T x_k \\ \text{subject to } & \alpha_i \geq 0 \text{ and } \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$


Veamos cómo podemos resolver este problema (**hard-margin SVM**)

$$\begin{aligned} \max_{\alpha_i \geq 0} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{k=1}^N \alpha_i \alpha_k y_i y_k x_i^T x_k \\ \text{subject to} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

Condición de optimalidad (KKT) $\rightarrow$ and $\alpha_i [y_i(x_i^T \beta + \beta_0) - 1] = 0 \forall i$

Esta última restricción (KKT) es fundamental para entender los SVM:

- Si $\alpha_i > 0$, $y_i(x_i^T \beta + \beta_0) = 1$ (el punto queda sobre el límite del margen)
- Si $y_i(x_i^T \beta + \beta_0) > 1$ (punto queda fuera del margen), $\alpha_i = 0$.




El problema **dual**, permite una interpretación más clara de los **vectores de soporte**


$$\hat{y}_i = \text{sgn}(x_i^T \beta + \beta_0)$$

$$\beta = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\alpha_i [y_i (x_i^T \beta + \beta_0) - 1] = 0 \quad \forall i$$




¿Qué pasa con el SVM si tenemos datos no son linealmente separables?




$$\frac{1}{\|\beta\|} y_i (x_i^T \beta + \beta_0) \geq M$$

Soft-margin SVM



$$\frac{1}{\|\beta\|} y_i (x_i^T \beta + \beta_0) \geq M - \xi_i^*$$


Soft-margin SVM



$$\xi_i^* = M \xi_i$$

$$\frac{1}{\|\beta\|} y_i(x_i^T \beta + \beta_0) \geq M(1 - \xi_i)$$

Soft-margin SVM



$$y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i$$

Soft-margin SVM

$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 \quad \text{subject to} \quad \begin{cases} y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i \quad \forall i, \\ \xi_i \geq 0, \sum \xi_i \leq \text{constant}. \end{cases}$$




$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^N \xi_i$$

subject to $\xi_i \geq 0, y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i \quad \forall i$

Función objetivo de los SVM calza con lo planteado al inicio del curso

Función de pérdida: captura el rendimiento del modelo al cuantificar su error en los datos de entrenamiento

$$\operatorname{argmin}_W J(X, Y; W) = \lambda \mathcal{R}(W) + \sum_i^N \mathcal{L}(f(x_i; W), y_i)$$


Regularizador: función que induce sesgo inductivo en el modelo predictivo a través de sus parámetros


Función objetivo de los SVM calza con lo planteado al inicio del curso

Regularizador: función que induce sesgo inductivo en el modelo predictivo a través de sus parámetros

Función de pérdida: captura el rendimiento del modelo al cuantificar su error en los datos de entrenamiento


$$\min_{\beta, \beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^N \xi_i$$

subject to $\xi_i \geq 0, y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i \forall i$




Efecto de C y las variables variables Slack


- El hiperparámetro C controla el trade-off entre la minimización del margen y la cantidad de ejemplos mal clasificados
- Un valor pequeño de C privilegia un hiperplano de gran margen con muchos errores
- Un valor grande de C privilegia un hiperplano de margen pequeño con pocos errores



Soft-margin SVM



$C = 1000$



$C = 0.01$

- ¿Cuál de las dos soluciones tiene un mayor valor para la constante C ?
- ¿Cómo puedo estimar el valor óptimo de C ?

Cuáles son los conceptos centrales de la clase

- Concepto de margen y su relación con la generalización.
- Bases geométricas de SVM
- Problema de aprendizaje como un problema de optimización, una característica del ML moderno.
- Función objetivo con 2 términos: regularización + pérdida.

Pontificia Universidad Católica de Chile
Escuela de Ingeniería
Departamento de Ciencia de la Computación



IIC2613 - Inteligencia Artificial

Support Vector Machines (SVM)

Denis Parra
Dpto. Ciencia de la Computación