

Active Learning

IIC2613

Aprendizaje Activo con Datos Escasos

Denis Parra
Dpto. Ciencia de la Computación

Contenido

- **Motivación**
 - El costo del etiquetado
 - Ejemplo motivador
- **AL vs. Aprendizaje Pasivo**
- **El ciclo de Active Learning**
 - El Oráculo y tipos de consulta
- **Formalización del problema**

- **Estrategias de consulta**
 - Uncertainty, Margin, Entropy
 - Query by Committee
 - Expected Model Change
- **Implementación con sklearn**
- **Gráficos y resultados**
- **Desafíos y Conclusiones**

- **Código con sklearn**
 - Loop básico de AL
 - modAL: ActiveLearner
- **Resultados**
 - Curvas de aprendizaje
 - Tablas comparativas

Motivación: ¿Por qué Active Learning?

- El aprendizaje supervisado requiere grandes cantidades de datos etiquetados
- Etiquetar datos es costoso, lento y requiere expertos
 - Imágenes médicas: diagnóstico por especialista
 - Textos legales: abogados especializados
 - Datos satelitales: analistas geoespaciales
- Pregunta clave: ¿podemos aprender bien con menos etiquetas?
- **Active Learning elige estratégicamente qué ejemplos etiquetar**
 - Minimizar el costo de etiquetado
 - Maximizar la performance del modelo


El problema del etiquetado

- En ML supervisado: más datos etiquetados $\rightarrow$ mejor modelo
- El problema: abundancia de datos sin etiqueta, escasez de etiquetados
 - Web, sensores, logs $\rightarrow$ millones de ejemplos sin etiquetar
 - Etiquetar requiere tiempo, dinero y experiencia
- **Active Learning aborda este desbalance:**
 - Pool sin etiqueta: $U = \{x_1, x_2, \dots, x_n\}$
 - Pool etiquetado: $L = \{(x_i, y_i)\}$
 - Objetivo: maximizar performance con $|L|$ mínimo

Ejemplo: clasificación de biopsias

- Problema: clasificar imágenes histológicas (maligno / benigno)
- **Datos disponibles:**
 - 10.000 imágenes sin etiqueta (baratas de obtener)
 - Etiquetado requiere patólogo: ~\$50 por imagen
 - Presupuesto: 200 etiquetas (\$10.000 total)
- **Muestreo aleatorio: 200 ejemplos al azar → 72% accuracy**
 - Muchos ejemplos fáciles o redundantes
- **Active Learning: 200 ejemplos informativos → 89% accuracy**
 - Mismo presupuesto, mucho mejor resultado

Ejemplo: clasificación de biopsias



https://commons.wikimedia.org/wiki/File:Histopathology_of_lung_adenocarcinoma_with_acinar_pattern.png

Ejemplo Ilustrativo




Figure 2: An illustrative example of pool-based active learning. (a) A toy data set of 400 instances, evenly sampled from two class Gaussians. The instances are represented as points in a 2D feature space. (b) A logistic regression model trained with 30 labeled instances randomly drawn from the problem domain. The line represents the decision boundary of the classifier (accuracy = 0.7). (c) A logistic regression model trained with 30 actively queried instances using uncertainty sampling (accuracy = 0.9).

Aprendizaje Pasivo vs. Active Learning

Aprendizaje Pasivo

- Dataset etiquetado antes del entrenamiento
- El modelo no influye en la selección de datos
- Muchos ejemplos redundantes o fáciles
- Costo fijo: etiquetar todo el dataset

Active Learning

- Etiquetado iterativo guiado por el modelo
- El modelo elige qué ejemplos etiquetar
- Se enfoca en ejemplos informativos
- Misma performance con muchas menos etiquetas

El ciclo de Active Learning

1. Inicialización

Entrenar modelo inicial h_θ con pool L pequeño

2. Selección (Query Strategy)

Seleccionar $x^* = \varphi(U, h_\theta)$ del pool no etiquetado

3. Oráculo

Un experto etiqueta $x^* \rightarrow$ obtener (x^*, y^*)

4. Actualización

$L \leftarrow L \cup \{(x^*, y^*)\}$, $U \leftarrow U \setminus \{x^*\}$

5. Re-entrenamiento y criterio de parada

Repetir hasta alcanzar la performance deseada o agotar presupuesto B

El ciclo de Active Learning

1. Inicialización

Entrenar modelo inicial h_θ con pool L pequeño

2. Selección (Query Strategy)

Seleccionar $x^* = \varphi(U, h_\theta)$ del pool no etiquetado

3. Oráculo


Un experto etiqueta $x^* \rightarrow$ obtener (x^*, y^*)

4. Actualización

$L \leftarrow L \cup \{(x^*, y^*)\}$, $U \leftarrow U \setminus \{x^*\}$

5. Re-entrenamiento y criterio de parada

Repetir hasta alcanzar la performance deseada o agotar presupuesto B



Repetir hasta alcanzar el presupuesto B o la performance deseada

El Oráculo

- El oráculo es la fuente de etiquetas en Active Learning
- **En la práctica: un experto humano o proceso costoso**
 - Médico que diagnostica imágenes médicas
 - Abogado que clasifica documentos legales
 - Anotador humano en plataformas de crowd-sourcing
- **Supuesto estándar: oráculo perfecto (siempre correcto)**
- **Extensiones del oráculo:**
 - Oráculo imperfecto: puede cometer errores
 - Múltiples oráculos con distinta confiabilidad
 - Costo variable: $c(x^*)$ puede depender del ejemplo



domain expert

Escenarios de Active Learning

- **Membership Query Synthesis (MQS)**
 - El modelo genera ejemplos sintéticos para consultar
 - Riesgo: ejemplos poco realistas o fuera de distribución
- **Stream-Based Selective Sampling**
 - Los datos llegan en flujo; el modelo decide si consultar cada uno
 - Aplicación: sensores IoT, feeds de redes sociales
- **Pool-Based Active Learning (más común)**
 - Existe un pool U de datos no etiquetados disponibles
 - El modelo selecciona el mejor candidato del pool en cada iteración
 - En este curso: nos enfocamos en este escenario

Escenarios de Active Learning




Figure 4: Diagram illustrating the three main active learning scenarios.

Formalización del problema

- **Notación:**

- X : espacio de entrada, Y : espacio de etiquetas
- $U = \{x_1, \dots, x_n\}$: pool no etiquetado
- $L = \{(x_i, y_i)\}$: pool etiquetado
- $h_\theta : X \rightarrow Y$: modelo entrenado sobre L

- **Proceso iterativo (presupuesto B):**

- Selección: $x_t^* = \varphi(U, h_\theta)$ (query strategy)
- Etiquetado: $y_t = \text{Oracle}(x_t^*)$
- Actualizar: $L \leftarrow L \cup \{(x_t^*, y_t)\}$, $U \leftarrow U \setminus \{x_t^*\}$
- Re-entrenar: $\theta \leftarrow \operatorname{argmin}_\theta L(h_\theta, L)$

Estrategia de consulta (Query Strategy)

- La query strategy ϕ define cómo seleccionar x^* del pool U
- **Formulación general:**
 - $x^* = \operatorname{argmax}_{\{x \in U\}} \text{informativeness}(x, h_\theta)$
- **¿Qué hace informativo a un ejemplo?**
 - Alta incertidumbre: el modelo no sabe cómo clasificarlo
 - Alta representatividad: cubre región no explorada del espacio
 - Mayor variación esperada: su etiqueta cambiaría mucho el modelo
- **Las distintas estrategias definen "informativeness" de distinta manera**

Estrategias de consulta en Active Learning

A. Basadas en incertidumbre (Uncertainty-based)

- Uncertainty Sampling: menor $P(\text{clase más probable})$
- Margin Sampling: menor margen entre las dos clases más probables
- Entropy Sampling: mayor entropía $H[y|x, \theta]$

B. Basadas en comité

- Query by Committee (QBC): mayor desacuerdo entre modelos

C. Basadas en varianza esperada

- Expected Gradient Length (EGL): mayor cambio esperado en θ

D. Basadas en representatividad


- Core-Set: cubre mejor el espacio de features

A.1 Muestreo por Incertidumbre (Uncertainty Sampling)

- La estrategia más simple y más usada en la práctica
- **Selecciona el ejemplo con menor probabilidad de la clase más probable:**
 - $x^* = \operatorname{argmin}_{\{x \in U\}} \max_{\{y \in Y\}} P(y \mid x, \theta)$
- Intuición: si la clase más probable tiene baja probabilidad $\rightarrow$ alta incertidumbre
- **Para clasificación binaria:**
 - $x^* = \operatorname{argmin}_{\{x \in U\}} |P(y=1|x,\theta) - 0.5|$
- **Ventajas y desventajas:**
 - Simple y eficiente computacionalmente
 - Puede sobre-sampear regiones ruidosas (outliers)
 - En SVM: seleccionar x más cercano al hiperplano de separación


A.2 Muestreo por Margen (Margin Sampling)

- Considera las dos clases más probables para tomar la decisión
- **Selecciona el ejemplo con menor margen entre ellas:**
 - $x^* = \operatorname{argmin}_{\{x \in U\}} [P(y_1^*|x, \theta) - P(y_2^*|x, \theta)]$
 - y_1^*, y_2^* : primera y segunda clase más probable
- Intuición: si el margen es pequeño $\rightarrow$ el modelo duda entre dos opciones
- **Ventaja sobre Uncertainty Sampling en multiclase:**
 - Más informativo: ignora clases con probabilidad muy baja
 - En binario: equivalente a Uncertainty Sampling



A.3 Muestreo por Entropía (Entropy Sampling)

- Usa toda la distribución de probabilidad sobre las clases
- **Selecciona el ejemplo con mayor entropía:**
 - $x^* = \operatorname{argmax}_{x \in U} H[y|x, \theta]$
 - $H[y|x, \theta] = -\sum_y P(y|x, \theta) \log P(y|x, \theta)$
- Entropía máxima = $\log(K)$ cuando $P(y|x) = 1/K$ (K clases)
- **Relación con otras estrategias:**
 - En binario: equivalente a Uncertainty y Margin Sampling
 - En multiclase: captura mejor la incertidumbre global
- **Ventaja: principled (teoría de la información)**



Izquierda: $H(p) = -p \cdot \log_2(p) - (1-p) \cdot \log_2(1-p)$.

Derecha: Uncertainty, Margin y Entropy Sampling comparados en p_1 .

B. Consulta por Comité (Query by Committee)

- Se entrena un comité de C modelos: $\{h_1, h_2, \dots, h_C\}$ sobre versiones de L
- Diversidad mediante: bootstrap, hiperparámetros distintos, modelos heterogéneos
- **Selección: ejemplo con mayor desacuerdo en el comité**
 - Vote entropy: $x^* = \arg\max_x -\sum_y \frac{V(y)}{C} \cdot \log(V(y)/C)$
 - $V(y)$: número de modelos del comité que votan la clase y
- **Ventajas y desventajas:**
 - Captura incertidumbre epistémica (varianza del modelo)
 - C veces más costoso en entrenamiento
 - Útil con Random Forests: cada árbol es un miembro del comité




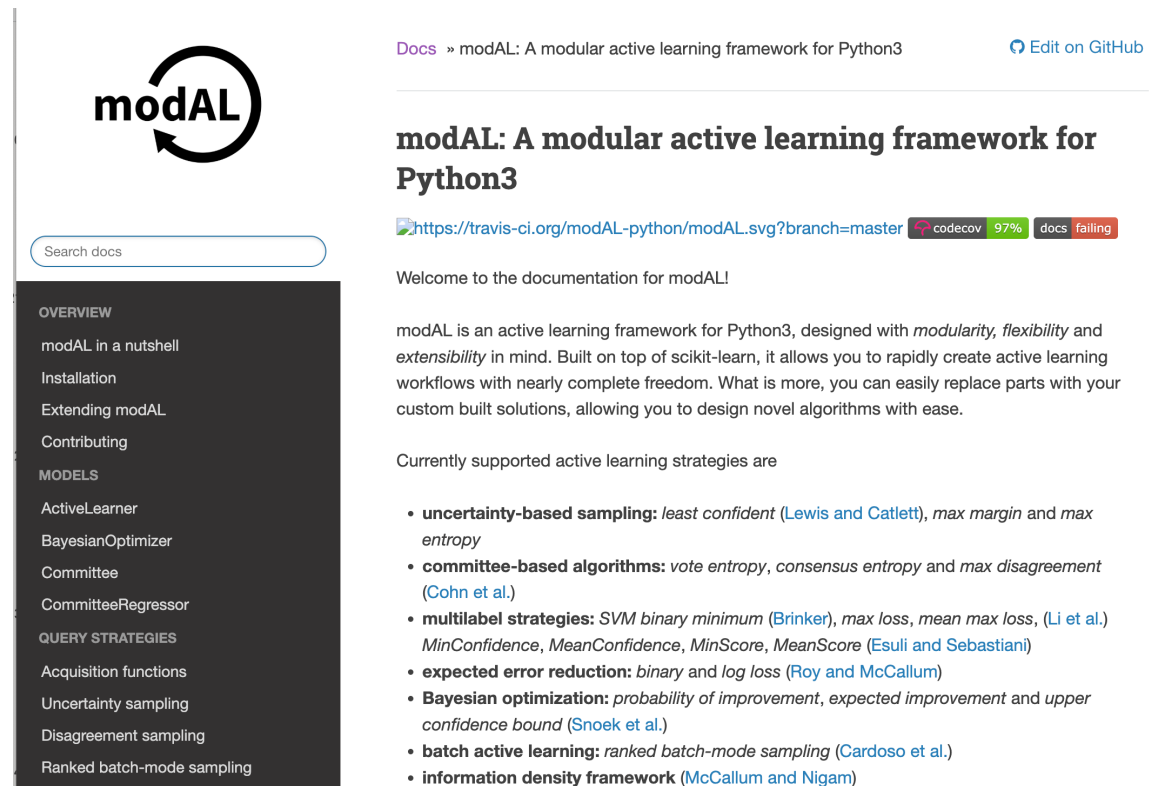
Figure 5: Version space examples for (a) linear and (b) axis-parallel box classifiers. All hypotheses are consistent with the labeled training data in $\mathcal{L}$ (as indicated by shaded polygons), but each represents a different model in the version space.

Otras estrategias avanzadas

- **C) Expected Gradient Length (EGL)**
 - Selecciona el ejemplo que generaría el gradiente de mayor norma
 - $x^* = \operatorname{argmax}_{\{x \in U\}} \sum_y P(y|x, \theta) \cdot ||\nabla_{\theta} L(h_{\theta}, (x, y))||$
 - Desventaja: costoso (requiere un paso de gradiente por cada candidato)
- **D) Core-Set (basado en representatividad)**
 - Objetivo: cubrir todo el espacio de entrada con mínimas etiquetas
 - Formulación: problema de k-center greedy
 - $x^* = \operatorname{argmax}_{\{x \in U\}} \min_{\{x_L \in L\}} ||\varphi(x) - \varphi(x_L)||$
 - Útil para garantizar cobertura geométrica del espacio

Implementación con scikit-learn

- Biblioteca principal: modAL (sobre scikit-learn)
- Compatible con cualquier estimador sklearn
- Instalación: **`pip install modal-python`**
- Implementa: uncertainty, margin, entropy sampling y QBC
- Alternativa: implementación manual con `predict_proba()` de sklearn



The screenshot shows the official documentation for modAL, a modular active learning framework for Python3. The page features a dark sidebar with a navigation menu. The main content area includes a welcome message, a description of the framework, and a list of supported active learning strategies.

modAL

Search docs

OVERVIEW

- modAL in a nutshell
- Installation
- Extending modAL
- Contributing

MODELS

- ActiveLearner
- BayesianOptimizer
- Committee
- CommitteeRegressor

QUERY STRATEGIES

- Acquisition functions
- Uncertainty sampling
- Disagreement sampling
- Ranked batch-mode sampling

Docs » modAL: A modular active learning framework for Python3 [Edit on GitHub](#)

modAL: A modular active learning framework for Python3

<https://travis-ci.org/modAL-python/modAL.svg?branch=master> [codecov](#) 97% [docs](#) failing

Welcome to the documentation for modAL!

modAL is an active learning framework for Python3, designed with *modularity*, *flexibility* and *extensibility* in mind. Built on top of scikit-learn, it allows you to rapidly create active learning workflows with nearly complete freedom. What is more, you can easily replace parts with your custom built solutions, allowing you to design novel algorithms with ease.

Currently supported active learning strategies are

- **uncertainty-based sampling:** *least confident* ([Lewis and Catlett](#)), *max margin* and *max entropy*
- **committee-based algorithms:** *vote entropy*, *consensus entropy* and *max disagreement* ([Cohn et al.](#))
- **multilabel strategies:** *SVM binary minimum* ([Brinker](#)), *max loss*, *mean max loss*, ([Li et al.](#)) *MinConfidence*, *MeanConfidence*, *MinScore*, *MeanScore* ([Esuli and Sebastiani](#))
- **expected error reduction:** *binary* and *log loss* ([Roy and McCallum](#))
- **Bayesian optimization:** *probability of improvement*, *expected improvement* and *upper confidence bound* ([Snoek et al.](#))
- **batch active learning:** *ranked batch-mode sampling* ([Cardoso et al.](#))
- **information density framework** ([McCallum and Nigam](#))

Código: Loop básico de Active Learning

- **Implementación manual con numpy + sklearn:**

```
import numpy as np
from sklearn.linear_model import LogisticRegression

model = LogisticRegression()
for iteration in range(budget):
    model.fit(L_X, L_y)
    proba = model.predict_proba(U_X)
    uncertainty = 1 - proba.max(axis=1)
    query_idx = np.argmax(uncertainty)
    # Oráculo: obtener etiqueta real
    L_X = np.vstack([L_X, U_X[[query_idx]]])
    L_y = np.append(L_y, y_true[query_idx])
    U_X = np.delete(U_X, query_idx, axis=0)
```

Código: Active Learning con modAL

```
from modAL.models import ActiveLearner
from modAL.uncertainty import (
    uncertainty_sampling,
    margin_sampling)
from sklearn.ensemble import
RandomForestClassifier

learner = ActiveLearner(
    estimator=RandomForestClassifier(),
    query_strategy=uncertainty_sampling,
    X_training=L_X, y_training=L_y)
```

```
for idx in range(n_queries):
    # Seleccionar ejemplo
    q_idx, q_inst = learner.query(U_X)

    # Etiquetar con oráculo
    y_new = oracle(q_idx)

    # Enseñar al modelo
    learner.teach(X=U_X[q_idx], y=y_new)
    U_X = np.delete(U_X, q_idx, axis=0)

    acc = learner.score(X_test, y_test)
```


Resultados: Curvas de Aprendizaje

- Las curvas de aprendizaje comparan estrategias en función del presupuesto
- **Eje X: número de ejemplos etiquetados (presupuesto usado)**
- **Eje Y: accuracy en conjunto de prueba**




Figure 3: Learning curves for text classification: **baseball vs. hockey**. Curves plot classification accuracy as a function of the number of documents queried for two selection strategies: uncertainty sampling (active learning) and random sampling (passive learning). We can see that the active learning approach is superior here because its learning curve dominates that of random sampling.

Resultados: Curvas de Aprendizaje

- Las curvas de aprendizaje comparan estrategias en función del presupuesto
- **Eje X: número de ejemplos etiquetados (presupuesto usado)**
- **Eje Y: accuracy en conjunto de prueba**
- Resultado típico en dataset breast cancer (sklearn, n=569):
 - Muestreo aleatorio: 72% accuracy con 100 etiquetas
 - Uncertainty Sampling: 88% accuracy con 100 etiquetas
 - Margin Sampling: 86% accuracy con 100 etiquetas
 - Entropy Sampling: 87% accuracy con 100 etiquetas
- La ventaja de AL es mayor con datos desbalanceados o ruidosos

Desafíos de implementación

- **Cold start problem**
 - Con L muy pequeño, las predicciones iniciales son poco confiables
 - Solución: inicialización aleatoria o clustering para los primeros ejemplos
- **Distributional shift**
 - El proceso de AL cambia la distribución de L iterativamente
 - El modelo puede sobreajustarse a regiones de alta incertidumbre
- **Costo computacional**
 - Re-entrenar en cada iteración es costoso para modelos grandes
 - Solución: batch mode — seleccionar k ejemplos por iteración
- **Oráculos ruidosos y escalabilidad**
 - Expertos cometen errores; crowd-sourcing con múltiples anotadores
 - Pools grandes: subsampling o aproximaciones eficientes del pool U

Conclusiones

- Active Learning reduce drásticamente el costo de etiquetado
 - Selección estratégica de ejemplos = misma performance con menos datos
- El ciclo iterativo (selección → oráculo → re-entrenamiento) es el núcleo de AL
- Las estrategias de incertidumbre son simples, eficientes y efectivas
 - Uncertainty, Margin, Entropy Sampling → buenas líneas base
- QBC y métodos avanzados ofrecen mayor riqueza a mayor costo computacional
- La implementación con sklearn/modAL es directa y accesible
- **Especialmente valioso cuando:**
 - Datos sin etiqueta son abundantes y el etiquetado es costoso
 - Se trabaja en dominios especializados: medicina, derecho, NLP

Preguntas y discusión

- dparras@uc.cl